



**Universidad
Indoamérica**

UNIVERSIDAD INDOAMÉRICA

MANUAL DE USUARIO

Modelo sustituto para calidad del aire en Quito: pronóstico y alerta temprana

Sistema de dos módulos: limpieza de datos REMMAQ y modelado con XGBoost

Autor: **Jonathan Alexander Cañar Quishpe**

Institución: **Universidad Indoamérica (UTI)**

Tipo de documento: **Trabajo de Titulación**

Versión del sistema: **v11.4 (XGBoost + SHAP + NiceGUI)**

Año: **2026**

MÓDULO 1: Limpieza y preparación REMMAQ

MÓDULO 2: Modelo IA + SHAP + IQCA

ÍNDICE DE CONTENIDOS

1. Introducción	3
1.1 Propósito del sistema	3
1.2 Público objetivo	3
1.3 Contaminantes y variables del sistema	3
2. Requisitos básicos	4
2.1 Software y hardware	4
2.2 Estructura de carpetas esperada	4
3. Flujo de trabajo integrado	5
3.1 Arranque y comandos de ejecución	5
4. Módulo 1 — Sistema de limpieza y preparación REMMAQ	6
4.1 ¿Qué hace este módulo?	6
4.2 Pantalla de inicio (Inicio-limpieza.png)	6
4.3 Carga de datos REMMAQ (carga_de_datos-limpieza.png)	7
4.4 Selección de parroquia y configuración (configuracion-limpieza.png)	8
4.5 Ejecución del pipeline y resultados (resultados-limpieza.png)	9
5. Módulo 2 — Sistema de modelado, métricas, SHAP y predicción	10
5.1 ¿Qué hace este módulo?	10
5.2 Dashboard principal (dashboard.png)	10
5.3 Carga de dataset y entrenamiento (entrenamiento.png)	11
5.4 Evaluación de métricas de precisión (metricas.png)	12
5.5 Visualización gráfica de rendimiento (metrica-grafica, graficas1, graficas2)	13
5.6 Interpretabilidad y gráficos SHAP (graficas3.png)	14
5.7 Predicción puntual e inferencia IQCA (prediccion.png)	15
6. Solución de problemas comunes	16
7. Recomendaciones de uso	16
8. Información del proyecto	16

1. INTRODUCCIÓN

1.1 Propósito del sistema

El presente manual describe el funcionamiento y la operación del sistema informático desarrollado como parte del trabajo de titulación "*Modelo sustituto para calidad del aire en Quito: pronóstico y alerta temprana*" de la Universidad Indoamérica. La plataforma está diseñada para preprocesar, modelar y analizar la concentración de contaminantes atmosféricos en el Distrito Metropolitano de Quito (DMQ) a partir de datos históricos de la Red Metropolitana de Monitoreo Atmosférico de Quito (REMMAQ).

Declaración de estado del sistema: El software es un **prototipo académico** de investigación. No constituye un sistema oficial de alerta en producción, no reemplaza la infraestructura física de la REMMAQ ni sustituye la gestión oficial del Municipio de Quito.

1.2 Público objetivo

- **Investigadores y analistas ambientales:** Requieren procesar mediciones brutas de estaciones de monitoreo, entrenar modelos de Inteligencia Artificial y evaluar patrones meteorológicos.
- **Técnicos de salud y medio ambiente:** Encargados del análisis preventivo de la calidad del aire y la simulación de escenarios de contaminación.
- **Estudiantes universitarios:** Interesados en la aplicación de Machine Learning y series temporales a problemas ambientales.

1.3 Contaminantes y variables del sistema

El sistema procesa 11 variables clave (6 contaminantes y 5 variables meteorológicas). La herramienta requiere al menos 10 variables presentes por parroquia (máximo 1 variable faltante):

Variable	Tipo	Descripción	Unidad
PM25	Contaminante Target	Material particulado fino (diámetro $\leq 2.5 \mu\text{m}$)	$\mu\text{g}/\text{m}^3$
PM10	Contaminante Target	Material particulado grueso (diámetro $\leq 10 \mu\text{m}$)	$\mu\text{g}/\text{m}^3$
O3	Contaminante Target	Ozono troposférico	$\mu\text{g}/\text{m}^3$
CO	Contaminante Target	Monóxido de carbono	mg/m^3
NO2	Contaminante Target	Dióxido de nitrógeno	$\mu\text{g}/\text{m}^3$
SO2	Contaminante Target	Dióxido de azufre	$\mu\text{g}/\text{m}^3$
Temperatura	Meteorológica	Temperatura ambiente	$^{\circ}\text{C}$
Humedad	Meteorológica	Humedad relativa	%
Viento_Velocidad	Meteorológica	Velocidad del viento	m/s
Viento_Direccion	Meteorológica	Dirección del viento	$^{\circ}$
Precipitacion	Meteorológica	Precipitación acumulada	mm

2. REQUISITOS BÁSICOS

2.1 Software y hardware

Componente	Requisito Mínimo	Notas de Configuración
Sistema Operativo	Linux, macOS o Windows 10/11	Consola estándar de comandos (Bash o PowerShell)
Entorno Python	Python 3.9 o superior	Se recomienda usar entorno virtual (venv o conda)
Navegador Web	Chrome, Firefox, Edge o Safari	Navegador moderno para renderizar la interfaz NiceGUI
Hardware	4 GB RAM, Procesador Dual-Core	GPU NVIDIA opcional (acelera entrenamiento XGBoost)
Archivos REMMAQ	Archivos Excel (.xlsx) o CSV	Nombres esperados: PM2.5.xlsx, TMP.xlsx, HUM.xlsx, etc.

2.2 Estructura de carpetas del proyecto

- **datos_remmaq/** — Carpeta donde se depositan los archivos brutos de la REMMAQ (.xlsx o .csv).
- **uploads_csv/** — Carpeta de salida del Módulo 1 donde se guarda el CSV limpio generado.
- **uploads/** — Carpeta de entrada del Módulo 2 para cargar el CSV limpio.
- **resultados_surrogate/** — Carpeta de salida del Módulo 2 para exportar los gráficos SHAP (.png) y modelos (.pkl).

3. FLUJO DE TRABAJO INTEGRADO

El sistema opera mediante una **secuencia obligatoria de dos etapas**. El Módulo 1 limpia las mediciones atmosféricas brutas y genera el dataset consolidado. El Módulo 2 consume este dataset para entrenar la Inteligencia Artificial y realizar la inferencia.

■ Secuencia obligatoria de operación

No intentes cargar archivos Excel brutos en el Módulo 2. Primero debes procesar los datos en el Módulo 1 para generar el archivo CSV con ingeniería de características y retardo temporal.

MÓDULO 1 — script_limpieza_niceGUI.py

1. Archivos REMMAQ (.xlsx) cargados por el usuario
2. Validación de completitud por parroquia (11 variables requeridas)
3. Limpieza: valores anómalos (−999) → NaN y rangos válidos
4. Exclusión opcional de período pandemia COVID-19 (2020–2021)
5. Filtro de silencios de sensores > 24 h (umbral fijo interno)
6. Lags de PM25 (1h, 3h, 24h) + codificación cíclica hora/mes



Genera dataset limpio: **dataset_ml_<parroquia>.csv**

MÓDULO 2 — modelo_ia_niceGUI_SHAP.py

1. Carga del CSV limpio procesado por el Módulo 1
2. Selección del contaminante objetivo (PM25, PM10, O3, CO, NO2 o SO2)
3. Feature Engineering avanzado (rolling means, diffs, interacciones meteo)
4. Selección automática de top-40 features (RandomForest + SelectFromModel)
5. Entrenamiento XGBoost con TimeSeriesSplit K=5 y temprana parada
6. Evaluación de métricas (R^2 , MAE, RMSE en conjunto de prueba)
7. Explicabilidad SHAP (contribución aprendida por el modelo — no implica causalidad)
8. Predicción puntual → concentración estimada → cálculo IQCA

3.1 Arranque y comandos de ejecución

Módulo	Script	Puerto	Comando Linux / macOS	Comando Windows (PowerShell)
Módulo 1 (Limpieza)	script_limpieza_niceGUI.py	3002	python script_limpieza_niceGUI.py PORT=3002 python script_limpieza_niceGUI.py	python script_limpieza_niceGUI.py \$env:PORT=3002; python script_limpieza_niceGUI.py
Módulo 2 (Modelo IA)	modelo_ia_niceGUI_SHA P.py	3000	python modelo_ia_niceGUI_SHAP.py PORT=3000 python modelo_ia_niceGUI_SHAP.py	python modelo_ia_niceGUI_SHAP.py \$env:PORT=3000; python modelo_ia_niceGUI_SHAP.py

■ Acceso desde el navegador

Una vez iniciado el script, abre tu navegador e ingresa a: Módulo 1 → **http://localhost:3002** | Módulo 2 → **http://localhost:3000**.

4. MÓDULO 1 — SISTEMA DE LIMPIEZA Y PREPARACIÓN REMMAQ

MÓDULO DE TRABAJO: `script_limpieza_niceGUI.py` · Puerto por defecto: 3002

4.1 ¿Qué hace este módulo?

El Módulo 1 es la herramienta de preprocesamiento de series temporales. Transforma mediciones incompletas o con ruido de las estaciones de la REMMAQ en un dataset estructurado y listo para Machine Learning.

1 Paso 0 — Validación de completitud

Identifica las parroquias disponibles y verifica que cuenten con al menos 10 de las 11 variables requeridas.

2 Paso 1 — Carga y alineación temporal

Lee los archivos Excel/CSV y une las series temporales por la columna Fecha (Timestamp).

3 Paso 2 — Depuración de errores de sensor

Convierte valores nulos (-999, -9999, 9999) a NaN y filtra rangos físicamente imposibles (ej. PM25 fuera de 0–400 $\mu\text{g}/\text{m}^3$).

4 Paso 3 — Filtros de coherencia y pandemias

Aplica 3 reglas: R1 (elimina filas sin target PM25), R2 (elimina filas sin ningún contaminante), R3 (elimina bloques de silencio >24 h). Permite excluir opcionalmente el período de pandemia COVID-19 (2020–2021).

5 Paso 4 — Ingeniería de variables temporales

Genera variables de retardo (lag_1h, lag_3h, lag_24h de PM25) y codificación cíclica (seno/coseno de hora del día y mes).

4.2 Pantalla de inicio

Al acceder a `http://localhost:3002`, el sistema presenta la pantalla de inicio con resúmenes de archivos detectados, parroquias válidas y excluidas por falta de datos.




Figura 1. Pantalla principal del Módulo 1 (`script_limpieza_niceGUI.py`). Muestra contadores de archivos y resumen del pipeline.

4.3 Carga de datos REMMAQ

En la pestaña «Carga de datos» se especifica la ruta del directorio local `datos\_remmaq/` o se suben manualmente los archivos Excel. El botón «Comprobar datos» ejecuta un diagnóstico en vivo sobre qué columnas fueron reconocidas y qué parroquias tienen completitud suficiente.




Figura 2. Sección Carga de datos (carga_de_datos-limpieza.png). Permite escanear carpetas locales o subir archivos Excel brutos.

■ Verificación de diagnóstico de archivos

Si la parroquia requerida no aparece, haz clic en 'Comprobar datos' para ver la lista de columnas detectadas y asegurarte de que los archivos contengan las cabeceras estándar de REMMAQ.

4.4 Selección de parroquia y configuración del pipeline

En la pestaña «Configuración» se selecciona la parroquia/estación de monitoreo objetivo (ej. Carapungo, Belisario, Cotocollao, Centro, Tumbaco). Permite activar la exclusión de pandemia y dar nombre al CSV de salida.




Figura 3. Panel de Configuración del pipeline (configuracion-limpieza.png). Selección de estación y parámetros del dataset.

■ Estaciones excluidas por falta de datos

El aviso en caja amarilla reporta qué parroquias fueron descartadas debido a que presentan más de 1 variable faltante. Para incluirlas, añade los archivos Excel correspondientes en `datos\_remmaq/`.

4.5 Ejecución del pipeline y resultados del dataset

Al presionar el botón «Construir Dataset ML», el pipeline procesa las series temporales en segundo plano. La pestaña **«Resultados»** exhibe la vista previa del dataset limpio, con sus columnas de retardo y codificación cíclica. El archivo final se exporta automáticamente a la carpeta `uploads\_csv/`.




Figura 4. Resultados del pipeline de limpieza (resultados-limpieza.png). Vista previa del DataFrame limpio generado con variables de retardo y marcas temporales.

■ Lectura correcta del CSV generado con Python

El archivo generado contiene metadatos institucionales comentados con el carácter '#'. Para leerlo en Pandas:

```
import pandas as pd
df = pd.read_csv('dataset_ml_carapungo.csv', comment='#', index_col='Timestamp', parse_dates=True)
```

5. MÓDULO 2 — SISTEMA DE MODELADO, MÉTRICAS, SHAP Y PREDICCIÓN

MÓDULO DE TRABAJO: `modelo_ia_niceGUI_SHAP.py` · Puerto por defecto: 3000

5.1 ¿Qué hace este módulo?

El Módulo 2 es la interfaz inteligente del sistema. Consume el CSV limpio generado por el Módulo 1, entrena un modelo de regresión sustituto **XGBoost** (`xgb.XGBRegressor`` con aceleración GPU o CPU), evalúa las métricas con validación cruzada para series temporales (**Time Series Split K=5**), calcula la interpretabilidad SHAP y permite obtener predicciones interactivas bajo demanda mediante el Índice de Calidad del Aire (IQCA).

Modelos por contaminante: El sistema entrena un modelo sustituto independiente para cada contaminante seleccionable (``PM25``, ``PM10``, ``O3``, ``CO``, ``NO2``, ``SO2``). No se aplica una regresión multisalida única.

5.2 Dashboard principal

Al acceder a `http://localhost:3000`, el Dashboard presenta un reloj gauge del promedio IQCA actual, el estado de conexión del modelo y un mapa interactivo de monitoreo de Quito.




Figura 5. Dashboard principal del Módulo 2 (dashboard.png). Presenta el estado del sistema, resumen IQCA y mapa de estaciones.

5.3 Carga de dataset y entrenamiento

En la sección **«Entrenamiento»**, el usuario arrastra el CSV limpio (ej. ``dataset_ml_carapungo.csv``), selecciona el contaminante objetivo (``PM25``, ``O3``, etc.) y decide si calcular la interpretabilidad SHAP. Al presionar 'Entrenar Modelo', el sistema ejecuta Feature Engineering avanzado (rolling means 3h/6h/12h/24h, diffs, interacciones meteo) y selecciona las top-40 variables mediante RandomForest antes de ajustar XGBoost.




Figura 6. Sección de Entrenamiento (entrenamiento.png). Carga del CSV procesado en el Módulo 1 y selección del contaminante target.

■ Aceleración por GPU

Si el servidor cuenta con una tarjeta NVIDIA, el sistema detecta automáticamente la GPU mediante ``nvidia-smi`` y activa el parámetro ``tree_method='hist`` con ``device='cuda`` para acelerar el entrenamiento.

5.4 Evaluación de métricas de precisión

En la sección «Métricas», el sistema reporta el Coeficiente de Determinación (R^2), el Error Absoluto Medio (MAE) y la Raíz del Error Cuadrático Medio (RMSE) evaluados sobre un conjunto de prueba cronológico ciego. Se presenta además una tabla resumen de la validación TimeSeriesSplit K=5 para todos los contaminantes evaluados.




Figura 7. Panel de Métricas de precisión. Reporte de R^2 , MAE, RMSE y resumen de validación TimeSeriesSplit.

■ Criterios de evaluación de precisión

Un valor de $R^2 \geq 0,80$ se considera referencia de ajuste aceptable para el modelo sustituto en series temporales atmosféricas. Si el R^2 de entrenamiento supera al de prueba en más de 0,15 ($\Delta R^2 > 0,15$), ello constituye un indicador orientativo de posible sobreajuste (overfitting) que debe analizarse en contexto.

5.5 Visualización gráfica de rendimiento

El módulo genera automáticamente gráficos de alta resolución para analizar el comportamiento del modelo sustituto. La Figura 8 ilustra el ajuste de la serie temporal entre los valores reales medidos por la REMMAQ y las estimaciones emitidas por XGBoost.




Figura 8. Gráfico de ajuste predictivo (metrica-grafica.png). Concentración Real vs. Predicha sobre la serie temporal de prueba.

La Figura 9 presenta la comparación de errores MAE/RMSE y el puntaje R² a lo largo de las 5 particiones temporales (K-Fold), junto con la curva de aprendizaje y el gráfico donut de importancia global de variables.




Figura 9. Análisis comparativo de métricas (graficas1.png). Curvas de aprendizaje, MAE/RMSE por contaminante y distribución de importancia.

5.5 Visualización gráfica de rendimiento (cont.)

La Figura 10 muestra la matriz de correlación de Pearson entre las variables meteorológicas y los contaminantes atmosféricos.



Figura 10. Matriz de correlaciones de Pearson (graficas2.png). Relación lineal entre variables meteorológicas y contaminantes.

5.6 Interpretabilidad y gráficos SHAP

La sección SHAP (SHapley Additive exPlanations) cuantifica la **contribución individual de cada variable** a las predicciones del modelo.

■ Interpretación correcta de los valores SHAP

Los valores SHAP demuestran qué variables afectaron la predicción matemática del modelo en una dirección positiva o negativa. NO demuestran causalidad física ni indican las 'causas reales' de la contaminación.




Figura 11. Gráfico SHAP Beeswarm / Feature Importance (graficas3.png). Demuestra el impacto y peso de las variables meteorológicas en las predicciones.

5.7 Predicción puntual e inferencia IQCA

La pestaña «Predicción IQCA» actúa como una calculadora interactiva. Permite ingresar valores meteorológicos actuales o hipotéticos (Temperatura, Humedad, Viento, Precipitación) y obtener la concentración estimada junto con su correspondiente categoría en el Índice de Calidad del Aire (IQCA).

■ Inferencia IQCA

El modelo XGBoost predice la concentración física del contaminante ($\mu\text{g}/\text{m}^3$). El IQCA es una transformación posterior basada en los umbrales oficiales del contaminante. Los resultados del IQCA son orientativos y no sustituyen los valores oficiales de la REMMAQ.

6. SOLUCIÓN DE PROBLEMAS COMUNES

Síntoma / Problema	Módulo	Causa Probable	Solución Recomendada
No aparecen parroquias al escanear	Módulo 1	Archivos no están en datos_remmaq/ o tienen nombres no reconocidos.	Verifica que los archivos se llamen ej. PM2.5.xlsx, TMP.xlsx y presiona Escanear.
Parroquia aparece como 'Excluida'	Módulo 1	La estación tiene 2 o más variables faltantes de las 11 requeridas.	Verifica que los archivos de esa estación contengan al menos 10 de las 11 variables.
Error al cargar CSV en Módulo 2	Módulo 2	Se intentó cargar un archivo Excel bruto en lugar del CSV del Módulo 1.	Asegúrate de seleccionar el CSV generado en uploads_csv/ (ej. dataset_ml_carapungo.csv).
Entrenamiento congelado o muy lento	Módulo 2	Cálculo SHAP requiere alta memoria en computadores sin GPU.	En la pestaña Entrenamiento, desmarca la casilla 'Calcular SHAP' para agilizar.
Predicción muestra 'Sin modelo'	Módulo 2	Se presionó 'Predecir' sin haber entrenado un modelo previamente.	Ve primero a la pestaña Entrenamiento, carga el CSV y entrena el modelo sustituto.

7. RECOMENDACIONES DE USO

7.1 Buenas prácticas para el Módulo 1

- Mantén los nombres originales de las variables en los archivos Excel de la REMMAQ.
- Utiliza la opción de excluir el período de pandemia (2020–2021) para evitar distorsiones meteorológicas en el entrenamiento.
- Verifica siempre la pestaña 'PERFIL' en los resultados para confirmar que el target PM25 no contenga valores nulos residuales.

7.2 Buenas prácticas para el Módulo 2

- Revisa que el coeficiente R^2 alcance o supere 0,80 como referencia de ajuste aceptable antes de utilizar el modelo para simulaciones.
- Analiza el gráfico SHAP para confirmar que variables como Temperatura y Velocidad del Viento tengan pesos coherentes.
- Recuerda que la calculadora IQCA está diseñada para simulación y pruebas de escenarios, no como sustituto de sensores oficiales.

7.3 Rendimiento y recursos

En equipos con GPU NVIDIA (Tesla/RTX), el entrenamiento toma entre 10 y 30 segundos. En equipos únicamente con CPU, el entrenamiento toma entre 1 y 3 minutos.

8. INFORMACIÓN DEL PROYECTO

Campo	Detalle Académico / Técnico
Título Oficial de la Tesis	Modelo sustituto para calidad del aire en Quito: pronóstico y alerta temprana
Autor	Jonathan Alexander Cañar Quishpe
Institución	Universidad Indoamérica (UTI)
Tipo de Documento	Trabajo de Titulación
Año	2026
Versión del Sistema	v11.4 — XGBoost + SHAP + NiceGUI
Archivos Fuente del Sistema	script_limpieza_niceGUI.py (Módulo 1) modelo_ia_niceGUI_SHAP.py (Módulo 2)
Librerías Clave	NiceGUI, XGBoost, Scikit-Learn, SHAP, Pandas, NumPy, Plotly

■ Aviso Institucional

Este manual y el software correspondiente forman parte del Trabajo de Titulación de la Universidad Indoamérica (UTI). Todos los derechos pertenecen al autor y a la institución conforme a la normativa académica vigente.